



Vision Transformer: 图像识别新范式




01

背景与动机



Transformer统治地位

自2017年Transformer问世，其自注意力机制与卓越的可扩展性，使其迅速成为NLP领域的主流架构。



CNN的统治

长期由卷积神经网络统治，其局部归纳偏置带来高效特征提取，但渴望更简洁、可扩展的替代方案。



卓越的可扩展性

预训练加微调范式推动模型参数突破**百亿**，性能持续攀升。



跨模态的启发

其成功引发思考：能否将纯Transformer直接应用于图像，**摆脱CNN**，实现跨模态统一架构？



ViT的机遇

前人尝试嵌入自注意力或替换卷积，但受限于**复杂性**与**硬件效率**，未能撼动ResNet。ViT旨在破局。




02

ViT模型概览




图像即序列：块嵌入策略


ViT将图像切分为固定尺寸补丁，展平并线性投影为向量序列，形成类似词元的结构。



ViT的整体流程



Transformer Encoder



$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}},$$
$$\mathbf{z}'_{\ell} = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1},$$
$$\mathbf{z}_{\ell} = \text{MLP}(\text{LN}(\mathbf{z}'_{\ell})) + \mathbf{z}'_{\ell},$$
$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0)$$

模型流程

1. 将图像分为一维度的系列
2. 在经过多头注意力获取每个patch之间的关系
3. 对第2步的关系进行MLP分类
(在每个层之间都做一个残差连接)

Transformer 编码器

由多头自注意力(MSA)和MLP块交替堆叠，辅以层归一化与残差连接。

低归纳偏置设计

ViT仅在补丁分割与位置编码处引入2D先验，其余层全局建模，舍弃卷积的局部与平移等变性。



03

训练与实验



不同模型之间的对比试验


实验表明:

ViT可以表现出的性能数据高于ResNet模型，但是效果数据差异不大。

作者从训练的时间来看，就单拿ViT-H/14看，训练时间是2500天；但是在ResNet与NetEfficientNet-L2相比少之又少。

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet Real	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

大规模预训练：性能的决定性因素



小数据集 (ImageNet)

模型表现不佳，ViT-Large 甚至低于 ViT-Base，因缺乏CNN的归纳偏置。

中数据集 (ImageNet-21k)

性能开始提升，ViT-Large 与 ViT-Base 表现相当，数据开始弥补偏置不足。


大数据集 (JFT-300M)

性能跨越式提升，ViT-Large 全面超越，验证“数据即归纳偏置”。

采用统一数据集对ViT训练时所需要参数数量的影响

在参数量比较小时ResNet高于ViT的全系列，但是随着数据量的不断增加，ViT的精度不断提高，其中ViT-L/16模型已经超过ResNet的精度

Transformer, ResNet与混合模型的分析



不同模型的精度分析

当数据量小时，混合模型的精度是远远高于ResNet与ViT的精度，因为它结合了两者的共同优点；但是随着数据量的不断提高，这些优点会慢慢消失，甚至被ViT模型反超。

缩放定律与模型选型



性能 vs. 计算量

ViT普遍位于曲线上方，用2-4倍更少算力即可达到ResNet同等精度。




缩放维度

深度缩放收益最大，宽度次之。减小补丁尺寸亦可提升表现。


混合架构仅在小算力区间略优，大模型差距消失，纯Transformer已足够强大。

ViT的深度分析




左图:

反映了第一层学习到的图像特征联系。说明学习到的低维基函数，为后续自注意力机制整合全局信息奠定了基础。



中图:

反映了位置信息编码信息，由图中我们可以看到每个patch都有自己的联系是最为密切地，并且呈现出从该点到四周的不断递减。并且可以用1维度的信息表现2维向量



右图:

反映了在初次多头注意力时，最低层部分注意力头已可跨越大半幅图像，随层深增加，平均注意力距离持续扩大。

ViT带来的启示



打破CNN惯性

以极简结构证明，通用自注意力机制足以学习图像特征。



数据与规模驱动

低归纳偏置让模型容量更依赖数据与规模。



架构统一

推动视觉与语言架构统一，加速多模态融合研究。



恳请老师批评指正